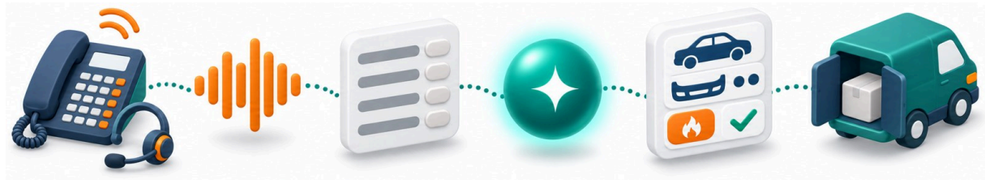
T07 · 인간-인공지능협업제품서비스설계 · 7번 아이템

콜노트(가칭) 시스템 구성도

서버 · 사이트 기능 · AI 모델 · 음성 처리가 어떻게 이어져 도는지 한 장에 모았다.
전화 주문 녹음이 들어오면 **PC 의 Whisper 가 받아쓰고, 서버의 Claude 가 주문 카드로 정리**하고, **사람이 확인 · 확정**한다.

AI 초안 · 돌린 사람: 배*결 · 검토 전 | 2026-11-12 기준 · dev 가지 | 데모는 가짜 통화만 쓴다



① 쓰는 곳 — 현장의 기기



누구나 · 브라우저만 있으면

휴대폰 · 태블릿 · PC

- 설치 없이 주소로 접속(홈 화면 추가 가능)
- 통화 목록 · 카드 · 찾기 · 묻기 · 브리핑을 본다
- **실시간 받아쓰기 체험**은 브라우저 음성 인식(Web Speech, 크롬 계열) — 음성은 브라우저 회사 서버가 처리



대리점 · 녹음이 쌓이는 PC

PC 프로그램 (폴더 감시)

- `src/pc-agent` 의 **watch** 모드
- 녹음 폴더에 새 파일이 생기면 서버로 올림
- 파일 이름은 중립 이름으로 바꿔 보냄 · 이미 보낸 파일은 다시 안 보냄(처음 켤 때 `--skip-existing` 이면 있던 파일 건너뜀)
- 걸려 온 번호는 안 보냄 > 이 길로 온 녹음은 번호로 거래처 맞추기(F11) 안 됨



그래픽카드 있는 PC · 지금은 배*결 PC

받아쓰기 일꾼 (Whisper)

- **faster-whisper large-v3** · GPU(RTX 5060 Ti) · float16
- 서버에서 일감을 **가져가서** 받아쓰고 결과를 돌려줌(서버가 PC 로 못 들어옴)
- 낱말 사전(현장 말)을 힌트로 씀 · 20초마다 「살아 있음」 신호
- 3분 통화 약 12.6초 · PC 가 꺼지면 받아쓰기는 줄 서서 기다림

HTTPS 화면 · API
녹음 올리기 · 카드 고치기 · 찾기 · 묻기

녹음 파일 보내기
`POST /api/ingest`
올리기 토큰

일감 가져가기 > 16kHz WAV
받아쓴 글 · 문장 시각 돌려줌
일꾼 토큰

② 데모 서버 — 모든 데이터와 화면이 사는 곳



AWS Lightsail · 서울 리전

2 vCPU · RAM 1GB · Ubuntu 24.04 · 같은 서버에 다른 실서비스가 함께 돈다

https://t07.3-39-67-126.sslip.io — Caddy 가 HTTPS 인증서를 자동으로 받는다

웹 앱 `src/app`
- Node 24 · 빌드 없음 · 직접 의존성은 Claude SDK 하나
- 화면(`public/`)과 API(`routes/`)를 함께 냄
- 전용 사용자로 가둠 · 메모리 300MB 상한

녹음 변환 · 일감 줄
- 올라온 녹음을 **ffmpeg** 로 16kHz 모노 WAV 로 바꾸고 원본은 지움
- 받아쓸 일감을 줄 세우고 일꾼에게 빌려줌 · 10분 안에 답이 없으면 다시 줄로(3번까지)

데이터베이스 `node:sqlite`

calls 통화 | cards 카드 | jobs 일감 | workers 일꾼 | glossary 낱말 사전 | briefings 브리핑 | trials 체험 신청 | usage 사용량

오디오 WAV 도 서버 디스크에 · 시각은 UTC 로 저장, 「오늘」은 한국 시간

데모 데이터
- **가짜 통화 61건**(대본 > 합성 음성 > 전화 음질)
- 10분마다 날짜를 오늘에 맞춰 다시 놓음 · 08:05 전에는 「어제 흐름」을 보임
- 관리자 「데모 초기화」로 처음 상태로

서로 막아 둔 것

공개 저장소의 코드를 자동으로 실행하므로, 앱은 따로 만든 사용자 · 정해진 폴더(`/var/lib/callnote`)에만 쓰게 가뒀다. 같은 서버의 다른 실서비스는 손대지 않는다. 녹음 보관용 **비공개 S3 버킷**은 만들어 두었지만 데모는 쓰지 않는다(실제 녹음 칸은 아무 키도 권한 없음).

받아쓴 글 + 낱말 사전 · 거래처 · 차종 목록

정해진 모양의 JSON 카드로 받음 (카드 · 브리핑 · 답)

데모 사이트의 AI 호출은 **서버에서만** 한다. 브라우저에는 키가 없다. (실제 녹음 시험만 PC 가 **가린 글**을 직접 보냄 — D)

③ AI — 글을 읽고 정리하는 곳



Claude API

Anthropic · 해외 서버

모델 `claude-opus-5-5` · 생각 깊이 `low` (빠르고 싸게)
구조화 출력: 정해진 JSON 모양으로만 답하게 함
안전 정책으로 거절하면 서버 쪽 **대체 모델**로 넘어감
상한: **하루 400번** · 기기(IP)당 하루 40번 · 10분 12번

주문 카드 정리 F04 · F05 · F07
거래처 · 차종 · 연식 · 차번호 · 부품 · 수량 · 급함 · 다시 물어볼 것. 칸마다 **그 말을 한 대목**을 근거로 붙임. **품번은 불러 준 것만**, 지어내지 않음.

오늘 브리핑 · 할 일 F10
숫자는 서버가 세고, AI 는 한 단락 요약과 「먼저 할 일」만 쓴다.

지난 통화에 묻기 F09
저장된 통화 글 · 카드만 근거로 답하고 **근거 통화 · 문장**을 붙인다. 없으면 「찾지 못했어요」.

Claude 는 **음성을 직접 받아쓰지 못한다** > 받아쓰기는 PC 의 Whisper(①) 또는 브라우저 음성 인식이 맡는다.

A 녹음 한 건이 카드가 되기까지

1. 브라우저 | PC 프로그램 — 녹음을 올린다(오디오만 · 10MB · 5분 이하)
2. 서버 — ffmpeg 로 16kHz WAV 로 바꾸고 일감 줄에 넣는다 — 화면에 「받아쓰기 기다리는 중」, 일꾼이 가져가면 「받아쓰는 중」
3. 일꾼 — 일감을 가져가 Whisper 로 받아쓴다(문장마다 시각 · 끝 시각)
4. Claude — 받아쓴 글 + 낱말 사전 · 거래처 · 차종 목록으로 카드를 만든다
5. 서버 — 검사: 품번(통화에서 불렀는지 · 자릿수) · 차번호 형식 > 노란 「들어 보기」, 걸려 온 번호로 거래처 맞추기. 비슷한 거래처는 Claude 가 「들어 보기」로 표시
6. 브라우저 — 사람이 칸을 누르면 그 대목부터 녹음 재생 > 고치고 **확정**(되물을 것이 남으면 확정 막힘) > 출고

실측(배포 주소): 1분 안팎 통화 하나를 올리면 약 12~20초 뒤 카드가 뜬다.

B 기능 15개는 어디서 도나 — 기획서 v1.3 · 구현-대조표 모두 「동작」

ID	기능	도는 곳
F01	녹음 올리기	브라우저 서버 일꾼
F02	받아쓰기(통화 글)	일꾼 Whisper · 문장 누르면 그 대목 재생
F03	실시간 받아쓰기 체험	브라우저 Web Speech > Claude
F04	주문 카드 자동 정리	Claude 구조화 출력
F05	근거 표시 · 들어 보기	서버 근거 문장 > 시각 · 브라우저 재생
F06	카드 고치기 · 확정	서버 DB · 확인 필요 > 확정 > 출고
F07	낱말 사전	서버 > 일꾼 힌트(현장 말) · Claude 기준
F08	통화 찾기	서버 글 · 카드 검색 · 맞은 문장 굵게
F09	지난 통화에 묻기	Claude 근거 인용
F10	오늘 브리핑 · 할 일	서버 집계 + Claude 한 단락
F11	번호로 거래처 맞추기	서버 거래처 목록과 번호 대조
F12	녹음 폴더 자동 보내기	PC 프로그램 > 서버
F13	거래처별 모아 보기	서버 DB
F14	출고 목록 내보내기	브라우저 인쇄 · 서버 CSV
F15	큰 글씨	브라우저 설정 기억

C 배포 — dev 에 푸시하면 끝



- 팀원은 **dev 가지에 푸시**만 한다(서버 접속 불필요)
- 서버가 **1분마다** GitHub 의 dev 를 확인해 새 커밋을 당겨 옴
- `npm ci` > 앱 다시 켜기 > `/healthz` 를 30초 안에 확인
- 실패하면 **앞 버전으로 자동 되돌림**
- 결과: `/_deploy/status.json`

GitHub 에는 비밀값 · 배포 키가 **하나도 없다**(서버가 공개 저장소를 당겨 가는 방식). 푸시마다 **gitleaks** 가 비밀값이 섞였는지 검사한다. `dev → main` 은 PR 로, 팀원 확인 뒤 합친다.

D 비밀값 · 실제 녹음



- Claude 키 · 토큰은 서버 설정 파일(관리자만 읽음)과 배*결 PC 비밀 폴더에만
- 브라우저 · 응답 · 로그 · 저장소에 키가 나가지 않음
- HTTPS 강제 · 보안 헤더 · 빈도 제한 · 위험한 동작은 관리자 암호
- 공개 데모는 **가짜 통화만** — 실제 녹음은 올리지 않음



실제 녹음 처리 — 코드 완료 · 가짜 61건 평가 · 실제 녹음은 아직

PC 안에서 받아쓰고 > **이름 · 전화 · 차번호 · 거래처 · 주소 · 계좌 · 메일을 PC 안에서 가명으로 가린 뒤** 가린 글만 Claude 로 > PC 안에서 원래 값으로 되돌림. 처음엔 `real_mode.py preview`(안 보냄)로 눈으로 확인. 결과 · 가명 대응표는 사이트 · 서버 · 저장소에 안 올림.